

人工智能导论第三次课程作业实验报告

实验题目：大语言模型部署体验与横向对比分析

姓名：薛毓哲

学号：2453619

班级：软件四班

提交日期：2026 年 5 月 12 日

项目公开可访问链接：<https://github.com/woody668/hw3-llm-modelscope>

一、实验目的

本次实验的主要目的是在 ModelScope 魔搭平台提供的 CPU Notebook 环境中，完成开源大语言模型的本地部署与推理测试，并通过统一测试问题比较不同模型在中文语义理解、歧义消解、多层逻辑推理和多义词解释任务上的表现。

实验选取 Qwen-7B-Chat、ChatGLM3-6B 和 Baichuan2-7B-Chat 三个中文对话模型作为测试对象，使用同一组中文问题进行问答测试。通过记录部署过程、模型输出结果和横向对比分析，了解不同大语言模型在复杂中文表达理解上的差异。

二、实验平台与环境

本次实验在 ModelScope Notebook 环境中完成，计算资源为 CPU 环境。实验过程中使用终端命令行安装依赖、下载模型权重，并通过 Python 脚本加载模型进行本地推理。

项目	内容
平台	ModelScope Notebook
计算资源	CPU，8 核 32GB
Python 版本	3.11
推理方式	本地加载模型进行推理
主要依赖	torch、transformers、modelscope、sentencepiece、tiktoken、einops、accelerate 等

```
root@dsw-1846721-c74f649b6-jgkd6:/mnt/workspace# python --version
python -c "import torch; print(torch.__version__)"
python -c "import modelscope; print(modelscope.__version__)"
python -c "import transformers; print(transformers.__version__)"
df -h
free -h
Python 3.11.11
2.9.1+cpu
1.35.0
5.3.0
文件系统
overlay
tmpfs
tmpfs
/dev/vda5
0cc8f49c66-xtf81.cn-hangzhou.nas.aliyuncs.com:/a02a29a1-803b-47a6-ale0-f713c33a2126/
overlay
/dev/vdb
tmpfs
tmpfs
tmpfs
tmpfs
tmpfs
大小 已用 可用 已用% 挂载点
98G 2.5M 98G 1% /
64M 0 64M 0% /dev
16G 0 16G 0% /sys/fs/cgroup
197G 69G 120G 37% /tmp
1.0P 25T 1000T 3% /mnt/data
197G 69G 120G 37% /etc/dsw
98G 2.5M 98G 1% /mnt/systemDisk
16G 0 16G 0% /dev/shm
16G 0 16G 0% /proc/acpi
16G 0 16G 0% /proc/scsi
16G 0 16G 0% /sys/firmware
total used free shared buff/cache available
内存: 30Gi 856Mi 8.4Gi 0.0Ki 21Gi 29Gi
交换: 0B 0B 0B
```

图 1 实验环境截图

图 1 展示了实验使用的 Python、PyTorch、ModelScope 版本，以及当前 Notebook 环境的 CPU、内存和磁盘情况，说明实验是在 ModelScope CPU Notebook 环境中完成的。

三、实验模型与测试任务设计

本次实验选取三个开源中文对话模型进行测试，分别为 Qwen-7B-Chat、ChatGLM3-6B 和 Baichuan2-7B-Chat。三个模型均为中文场景中较常见的大语言模型，具备对话生成能力，适合用于中文问答、语义理解和语言推理测试。

为了保证横向比较的公平性，三个模型使用完全相同的测试问题。测试问题主要来自作业给出的参考问题，重点考察模型对中文双关表达、歧义句、多层嵌套逻辑和多义词的理解能力。

编号	测试重点	问题内容
1	语境反转 / 双关	冬天：能穿多少穿多少；夏天：能穿多少穿多少
2	句法歧义	单身狗产生的原因有两个，一是谁都看不上，二是谁都看不上
3	多层逻辑嵌套	他知道我知道你知道他不知道吗？
4	中文分词与指代	明明明明白白白喜欢他，可她就是不

5	多义词解释	“意思”在连续对话中的不同含义
---	-------	-----------------

这些问题并不是普通知识问答，而是更侧重模型对中文语言现象的理解能力，因此可以较明显地区分模型在语义理解层面的表现差异。

四、模型部署与运行过程

本实验没有采用附件 2 中 Intel Extension for Transformers / Neural Chat 的 INT4 量化 chatbot 路线，而是参考其 ModelScope 平台使用流程，在 CPU Notebook 环境中直接通过 transformers 本地加载模型并进行问答推理。这样写法与现有项目代码、输出文件和截图保持一致。

进入项目目录后，首先通过 requirements.txt 安装运行依赖，主要包括 torch、transformers、modelscope、sentencepiece、tiktoken、einops、accelerate 等库。依赖安装命令如下：

```
pip install -r requirements.txt
```

三个模型均下载到 /mnt/data 目录下，分别对应 Qwen-7B-Chat、chatglm3-6b 和 Baichuan2-7B-Chat 三个子目录。模型权重体积较大，因此 GitHub 仓库中只保存代码、截图和输出结果，不上传模型权重文件。由于本次实验使用 CPU 环境，模型加载和生成速度较慢，所以选取 5 个具有代表性的中文语义理解问题进行验证。

项目	内容
Qwen-7B-Chat	https://www.modelscope.cn/qwen/Qwen-7B-Chat.git -> /mnt/data/Qwen-7B-Chat
ChatGLM3-6B	https://www.modelscope.cn/ZhipuAI/chatglm3-6b.git -> /mnt/data/chatglm3-6b
Baichuan2-7B-Chat	https://www.modelscope.cn/baichuan-inc/Baichuan2-7B-Chat.git -> /mnt/data/Baichuan2-7B-Chat

1. Qwen-7B-Chat 部署

首先在 /mnt/data 目录下使用 git clone 命令下载 Qwen-7B-Chat 模型权重文件。下载完成后，模型文件保存在 /mnt/data/Qwen-7B-Chat 路径下。随后运行 scripts/run_qwen_cpu.py 脚本，使用 transformers 加载 tokenizer 和模型，并对测试问题进行推理。

```
root@dsw-1846721-c74f649b6-jgkd6:/mnt/data# git clone https://www.modelscope.cn/qwen/Qwen-7B-Chat.git
正克隆到 'Qwen-7B-Chat'...
remote: Enumerating objects: 554, done.
remote: Counting objects: 100% (56/56), done.
remote: Compressing objects: 100% (30/30), done.
remote: Total 554 (delta 30), reused 49 (delta 26), pack-reused 498
接收对象中: 100% (554/554), 16.47 MiB | 5.88 MiB/s, 完成.
处理 delta 中: 100% (294/294), 完成.
正在更新文件: 100% (31/31), 完成.
过滤内容: 100% (8/8), 14.38 GiB | 12.06 MiB/s, 完成.
root@dsw-1846721-c74f649b6-jgkd6:/mnt/data# ls -lh /mnt/data/Qwen-7B-Chat | head
总计 15G
drwxr-xr-x 2 root root 4.0K 4月 28 15:19 assets
-rw-r--r-- 1 root root 8.3K 4月 28 15:19 cache_autogptq_cuda_256.cpp
-rw-r--r-- 1 root root 51K 4月 28 15:19 cache_autogptq_cuda_kernel_256.cu
-rw-r--r-- 1 root root 911 4月 28 15:19 config.json
-rw-r--r-- 1 root root 77 4月 28 15:19 configuration.json
-rw-r--r-- 1 root root 2.3K 4月 28 15:19 configuration_qwen.py
-rw-r--r-- 1 root root 1.9K 4月 28 15:19 cpp_kernels.py
drwxr-xr-x 2 root root 4.0K 4月 28 15:19 examples
-rw-r--r-- 1 root root 273 4月 28 15:19 generation_config.json
root@dsw-1846721-c74f649b6-jgkd6:/mnt/data# du -sh /mnt/data/Qwen-7B-Chat
29G /mnt/data/Qwen-7B-Chat
```

图 2 Qwen-7B-Chat 模型 git clone 下载结果

2. ChatGLM3-6B 部署

ChatGLM3-6B 模型通过 ModelScope 仓库地址下载到 /mnt/data/chatglm3-6b 目录。实验脚本 scripts/run_chatglm3_cpu.py 使用 AutoTokenizer 和 AutoModel 加载模型，并调用模型自带的 chat 接口完成问答测试。

```
root@dsw-1846721-c74f649b6-jgkd6:/mnt/data# git clone https://www.modelscope.cn/ZhipuAI/chatglm3-6b.git
正克隆到 'chatglm3-6b'...
remote: Enumerating objects: 147, done.
remote: Counting objects: 100% (7/7), done.
remote: Compressing objects: 100% (7/7), done.
remote: Total 147 (delta 0), reused 0 (delta 0), pack-reused 140
接收对象中: 100% (147/147), 77.69 KiB | 55.00 KiB/s, 完成.
处理 delta 中: 100% (64/64), 完成.
正在更新文件: 100% (28/28), 完成.
过滤内容: 100% (15/15), 23.26 GiB | 10.27 MiB/s, 完成.
```

图 3 ChatGLM3-6B 模型 git clone 下载结果

3. Baichuan2-7B-Chat 部署

Baichuan2-7B-Chat 模型下载到 /mnt/data/Baichuan2-7B-Chat 目录。实验脚本 scripts/run_baichuan2_cpu.py 使用 AutoModelForCausalLM 加载模型，并通过消息列表形式调用模型对话接口完成测试。

关键输出摘要如下：

题号	核心表现
1	正确识别冬天和夏天语境下同一句式的含义相反。
2	能意识到句子存在表达差异，但没有准确解释两个“谁都看不上”的方向差别。
3	重述了认知链条，但没有明确回答“到底谁不知道”。
4	回答为“她喜欢他”，没有准确区分“明明”和“白白”的指代关系。
5	能说明“意思”有多种含义，但解释偏概括，没有逐项对应到具体对话。

从测试结果看，Qwen-7B-Chat 在第 1 题中能够识别“冬天”和“夏天”语境下“能穿多少穿多少”的含义相反，说明模型具备一定的语境反转理解能力。但在第 3 题和第 4 题中，模型没有完全给出明确的指代结论，对多层嵌套逻辑和复杂中文分词的处理仍存在不足。第 5 题中，模型能够意识到“意思”具有多种含义，但解释偏概括，没有逐一对应每一次出现的“意思”。

2. ChatGLM3-6B 测试结果

```
Setting eos_token is not supported, use the default one.
Setting pad_token is not supported, use the default one.
Setting unk_token is not supported, use the default one.
/usr/local/lib/python3.11/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree.register_pytree_node` is deprecated. Please use `torch.utils._pytree.register_pytree_node` instead.
torch.utils._pytree.register_pytree_node(
/usr/local/lib/python3.11/site-packages/transformers/utils/generic.py:311: FutureWarning: `torch.utils._pytree.register_pytree_node` is deprecated. Please use `torch.utils._pytree.register_pytree_node` instead.
torch.utils._pytree.register_pytree_node(
Adding tokenizer...
Adding model...
Adding checkpoint shard: 100% 7/7 [00:03<00:00, 1.88it/s]
Model loaded.

=====
题 1: 请说出以下两句话区别在哪里？1、冬天：能穿多少穿多少 2、夏天：能穿多少穿多少
两句话的区别在于季节不同，穿着的暴露程度不同。
冬天：能穿多少穿多少，意味着冬天寒冷，应该穿较多衣服来保暖，避免感冒。
夏天：能穿多少穿多少，意味着夏天天气炎热，应该穿较少衣服来散热，保持舒适。

=====
题 2: 请说出以下两句话区别在哪里？单身狗产生的原因有两个，一是谁都看不上，二是谁都看不上
两句话都描述了单身狗的情况，但它们的表达方式略有不同。
一句话“单身狗产生的原因有两个，一是谁都看不上，二是谁都看不上”采用了“一是...二是...”的句式，强调单身狗单身的原因有两个，一个是看不上别人，另一个是别人也看不上他。这种表达方式比较直接，让人明确知道单身狗单身的原因。
第二句话“单身狗产生的原因有两个，一是谁都看不上，二是谁都看不上”则采用了“...因为...”的句式，强调单身狗单身的原因是因为看不上别人，同时也被别人看不上。这种表达方式比较婉转，让人感觉单身狗的孤独可能来自于自身的原因，也可能是环境原因。

=====
题 3: 他不知道我知道他知道他不知道吗？这句话里，到底谁不知道？
这句话是一个典型的悖论，因为它的含义是自相矛盾的。
第一个人“知道我知道”，那么这个人显然知道这个人不知道的事情。但是，如果这个人也“知道”这个人不知道的事情，那么这个人也显然知道这个事情，因为如果他知道这个事情，那么他就不会不知道它。
此，这句话的意思是，没有任何一个人知道这个事情，因为如果有人知道，那么这个人就会知道这个人不知道的事情，而如果有人不知道，那么这个人就会知道这个事情。这是一个典型的悖论，因为它在一个句子中包含了自相矛盾的信息。

=====
题 4: 明明明明白白白白喜欢他，可能就是不。这句话里，明明和白白谁喜欢谁？
这句话中可以看出，明明知道白白喜欢他，但是白白并没有表达出自己的喜欢。所以，在这种情况下，我们可以理解为明明知道白白喜欢他，但是白白并没有明确表达出来，而明明也没有表达出自己的感情。

=====
题 5: 领导：你这是什么意思？小明：没什么意思。意思意思。领导：你就不够意思了。小明：小意思，小意思。领导：你这个人真有意思。小明：其实也没有别的意思。领导：那我就不好意思了。小明：是我不好意思。请问：以上“意思”分别是什么意思？
“意思”作为名词，表示含义、意义、意思。例如：“这句话的意思是...”。
“意思”作为动词，表示表示、暗示、意味。例如：“他的话中暗示着...”。
“意思”作为形容词，表示客气、谦虚等。例如：“你客气的意思很头套。”
```

图 6 ChatGLM3-6B 在五个中文语义理解问题上的问答测试结果

关键输出摘要如下：

题号	核心表现
1	同样把夏天表达理解为多穿衣服，未识别双关含义。
2	对两个原因的解释偏离题目，未准确抓住句法歧义。
3	能直接指出“不知道”的对象是“他”，表现较好。
4	倾向于认为无法确定，说明对连续字串分词和指代消解不足。
5	尝试逐项解释“意思”，但部分解释与原对话语境对应不够准确。

Baichuan2-7B-Chat 的回答整体较为谨慎。第 3 题中，模型能够直接指出“不知道”的对象是“他”，这个回答较接近题目要求。但在第 1 题中，模型同样没有识别夏天语境下的反向含义；第 4 题中，模型认为无法确定明明和白白谁喜欢谁，说明其对中文连续字串中的分词和指代关系处理较弱。第 5 题中，模型尝试逐条解释“意思”，但部分解释与原对话语境对应不够准确。

六、不同大语言模型横向对比分析

测试维度	Qwen-7B-Chat	ChatGLM3-6B	Baichuan2-7B-Chat
语境反转理解	第 1 题能识别冬夏语境下同一句式含义相反，表现较好	第 1 题将夏天解释为多穿衣服散热，理解错误	第 1 题同样误解夏天表达，表现较弱
句法歧义理解	第 2 题能意识到句子存在差异，但解释不够准确	第 2 题能部分解释“看不上别人 / 被别人看不上”的区别	第 2 题对歧义理解较弱，解释偏离题目
多层逻辑推理	第 3 题能重述逻辑结构，但没有明确回答谁不知道	第 3 题将句子判断为悖论，没有回答“谁不知道”	第 3 题能直接指出“他”不知道，表现较好
分词与指代消解	第 4 题回答过于笼统，没有准确区分明	第 4 题对“白白喜欢他”的关系判断较接	第 4 题倾向于认为无法确定，表现较弱

	明和白白	近	
多义词语境解释	第 5 题能说明“意思”有多种含义，但没有逐项对应	第 5 题只做泛化解释，缺少语境分析	第 5 题尝试逐项解释，但准确性不足
输出完整性	回答较完整，语言流畅	表达流畅，但容易泛化或误判	较谨慎，但有时不够明确

综合五个测试问题可以看出，三个模型在中文普通问答中都能生成较流畅的自然语言回答，但在复杂中文语义理解任务上存在明显差异。Qwen-7B-Chat 的整体表现相对较好，尤其在第 1 题中能够根据“冬天”和“夏天”的语境差异判断同一句式的实际含义相反，说明其对常见中文生活语境和隐含语义有较好的把握。不过，Qwen 在多层逻辑和复杂指代问题上仍然存在不足，例如第 3 题只是重述了句子结构，没有明确回答“到底谁不知道”；第 4 题也没有准确区分“明明”和“白白”的指代关系。

ChatGLM3-6B 的回答语言较流畅，但在本次测试中容易将问题解释得过于抽象。例如第 3 题中，模型把原句解释为悖论，而题目实际更需要进行人物指代和认知关系分析。第 5 题中，ChatGLM3-6B 给出了“意思”的名词、动词、形容词等泛化解释，但没有结合每一句对话说明具体含义，因此没有完全完成题目要求。

Baichuan2-7B-Chat 的特点是回答相对保守，在不确定时倾向于给出无法判断的结论。它在第 3 题中能够指出“不知道”的对象是“他”，这一点表现较好；但在第 1 题和第 4 题中，对中文双关和连续字串分词的理解不足。第 5 题虽然尝试逐项解释，但部分解释与对话中的真实语境不完全匹配。

总体来看，在本次中文歧义理解测试中，Qwen-7B-Chat 的综合表现相对最好，能够较处理好语境反转和部分多义表达；ChatGLM3-6B 的回答流畅度较高，但在复杂逻辑和具体语境分析中容易泛化；Baichuan2-7B-Chat 在个别逻辑问题上表现较好，但整体准确性和细致程度略弱。需要注意的是，本实验测试问题数量有限，结论只反映三个模型在本组中文语义理解问题上的表现，不能直接代表模型在所有任务上的综合能力。

七、实验总结

通过本次实验，我完成了在 ModelScope CPU Notebook 环境中下载、部署和运行多个开源大语言模型的过程，熟悉了通过 transformers 加载 tokenizer 和模型、调用对话接口并保存模型输出的基本流程。实验结果表明，不同大语言模型虽然都能生成较自然的中文回答，但在中文歧义理解、复杂指代、多义词解释等任务上仍存在明显差异。

本次实验也说明，评价大语言模型不能只看回答是否流畅，还需要关注回答是否真正理解了问题中的语境、指代和隐含含义。对于中文双关、连续字串分词和多层逻辑问题，模型容易出现表面理解、过度泛化或回避判断等现象。后续如果进一步扩展实验，可以增加更多测试问题，并从准确率、回答完整性、推理过程和生成稳定性等方面进行更系统的评价。

八、附录：项目公开链接与代码说明

项目公开可访问链接：<https://github.com/woody668/hw3-llm-modelscope>

本项目仓库保存了实验 README、依赖列表、三个模型的运行脚本、终端输出结果以及部署和测试截图。由于模型权重文件体积较大，仓库中未包含模型权重，运行前需要在 ModelScope Notebook 环境中将模型下载到对应的 /mnt/data 路径。

项目	内容
Qwen-7B-Chat 脚本	scripts/run_qwen_cpu.py
ChatGLM3-6B 脚本	scripts/run_chatglm3_cpu.py
Baichuan2-7B-Chat 脚本	scripts/run_baichuan2_cpu.py
Qwen 输出	outputs/qwen_result.txt
ChatGLM3 输出	outputs/chatglm3_result.txt
Baichuan2 输出	outputs/baichuan2_7b_chat_result.txt

仓库目录结构说明如下：

README.md: 实验说明、环境信息、模型列表和结果索引
requirements.txt: 运行脚本所需 Python 依赖
scripts/: 三个模型的 CPU 推理脚本
outputs/: 三个模型的终端问答输出
screenshots/: 环境、模型下载和问答结果截图
report/: 本实验报告输出目录